PREDICTION DE FRAUDE

MED BAYREM BENKHOUD

4 DS 3

DÉTECTION DE FRAUDE EN ASSURANCE AUTOMOBILE

ANALYSE ET MODÉLISATION PRÉDICTIVE

- CONTEXTE : LA FRAUDE REPRÉSENTE 15% DES SINISTRES EN TUNISIE, GÉNÉRANT DES PERTES DE 200 MILLIONS DE DINARS
- OBJECTIF : DÉVELOPPER UN MODÈLE CAPABLE DE PRÉDIRE AUTOMATIQUEMENT LES DÉCLARATIONS DE SINISTRES FRAUDULEUSES
- DOMAINE : FINANCE / ASSURANCE
- MÉTHODOLOGIE : CRISP-DM AVEC COMPARAISON DE MODÈLES DE MACHINE LEARNING

APERÇU DU JEU DE DONNÉES ET PRÉTRAITEMENT

CE JEU DE DONNÉES DE 1 000 OBSERVATIONS (40 VARIABLES) PRÉSENTE UN FORT DÉSÉQUILIBRE AVEC 24,7 % DE FRAUDES. LE PRÉTRAITEMENT A CIBLÉ LE NETTOYAGE DES VALEURS MANQUANTES ET L'OPTIMISATION DES VARIABLES CLÉS POUR LA MODÉLISATION.

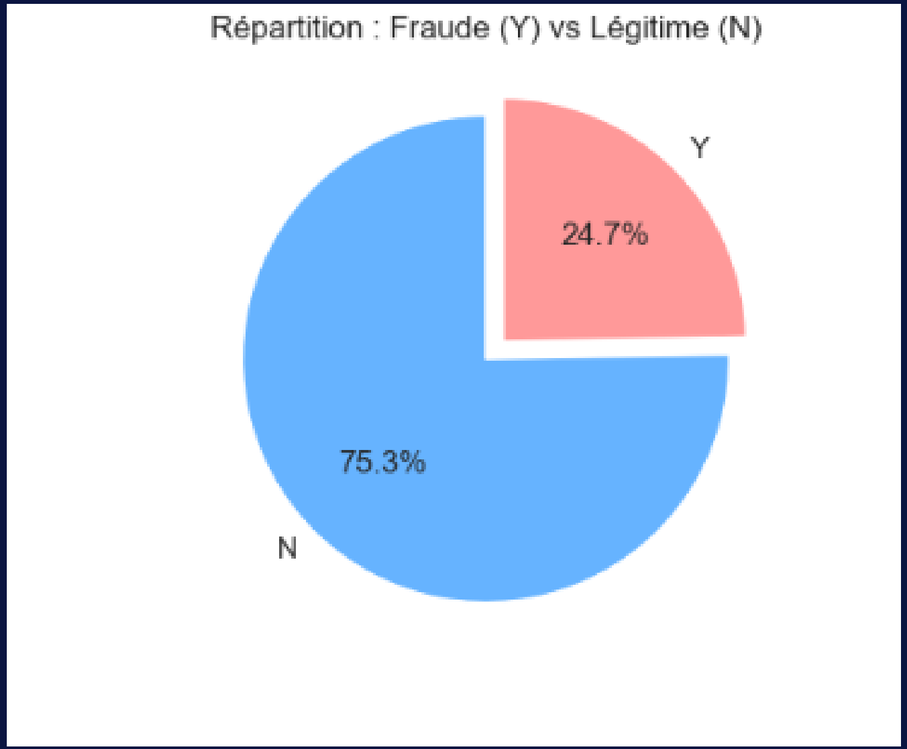

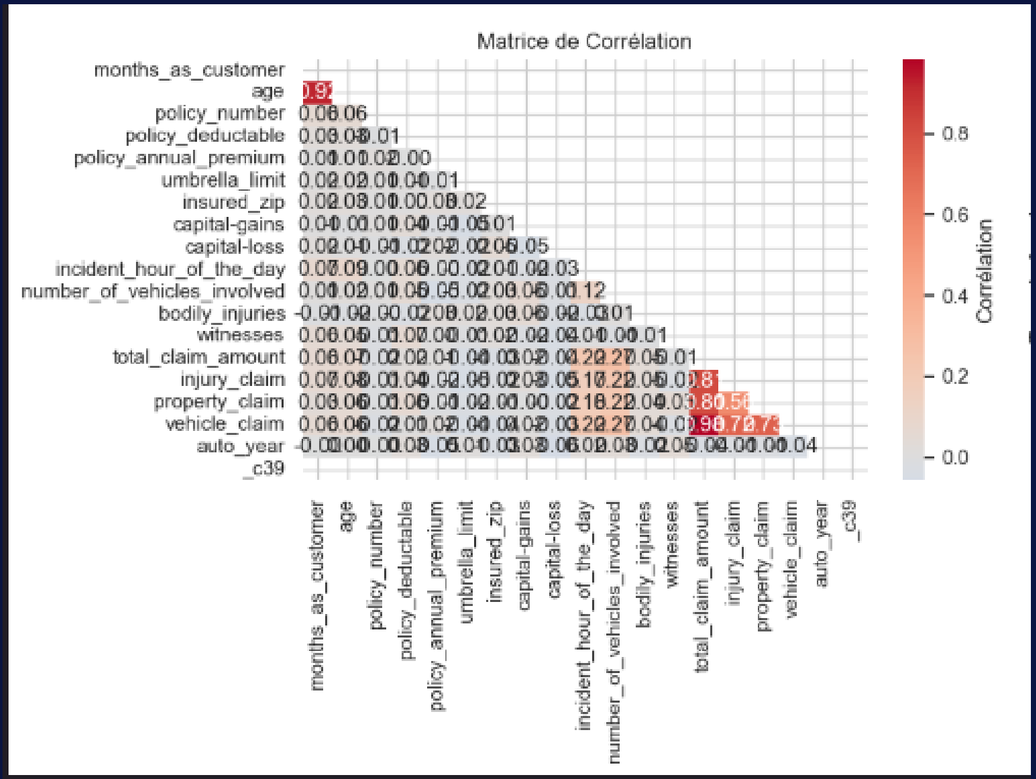

OBSERVATION : FORTE CORRÉLATION ENTRE TOTAL_CLAIM_AMOUNT ET LES SOUS-MONTANTS (INJURY, PROPERTY, VEHICLE).

P

POURQUOI : ÉVITER LA MULTICOLINÉARITÉ (REDONDANCE D'INFORMATIONS) QUI POURRAIT BIAISER CERTAINS ALGORITHMES COMME LA RÉGRESSION LOGISTIQUE.

NETTOYAGE DES DONNÉES (DATA CLEANING)

- RÉDUCTION DIMENSIONNELLE : SUPPRESSION DE 4 COLONNES NON PRÉDICTIVES (IDS, ADRESSES, CODES POSTAUX) POUR ÉVITER LE BRUIT.
- TRAITEMENT DES LACUNES : IMPUTATION DES VALEURS MANQUANTES (9,1 % SUR LES CONTACTS AUTORITÉS) POUR STABILISER LE DATASET.
- CORRECTION DES ANOMALIES : IDENTIFICATION ET REMPLACEMENT DES VALEURS ABERRANTES ("?") PAR DES MÉTHODES STATISTIQUES.
- STANDARDISATION CATÉGORIELLE : UNIFORMISATION DES TEXTES (MAJUSCULES) POUR ÉLIMINER LES DOUBLONS DE SAISIE.
- INGÉNIERIE TEMPORELLE : CONVERSION DES DATES (FORMAT DATETIME) POUR RENDRE LES DÉLAIS DE SINISTRES EXPLOITABLES.
- EXPORT FINAL : GÉNÉRATION D'UN FICHIER PROPRE DE 1000 LIGNES × 36 COLONNES PRÊT POUR L'IA

MODELISATION

OBJECTIF : CONSTRUIRE UN MODÈLE DE CLASSIFICATION BINAIRE POUR PRÉDIRE FRAUD_REPORTED.

1

LOGISTIC REGRESSION

- Définition : Algorithme de classification supervisée pour problèmes binaires
- Justification : Modèle de référence (baseline) simple et interprétable
- Avantage : Rapide à entraîner, permet de vérifier le signal dans les données

2

RANDOM FOREST

- Définition : Ensemble d'arbres de décision avec vote majoritaire
- Justification : Robuste au bruit et aux valeurs aberrantes
- Avantage : Gère bien le déséquilibre des classes, fournit l'importance des variables

3

XGBOOST (1)

- Définition : Gradient Boosting extrême - arbres corrigeant les erreurs précédentes
- Justification : Excellent sur données tabulaires, gère le déséquilibre des classes
- Avantage : Performances supérieures, outils d'explicabilité (SHAP)

4

CATBOOST (2)

- (Définition : Gradient Boosting optimisé pour variables catégorielles
- Justification : Gestion native des catégories, robuste au surapprentissage
- Avantage : Peu de tuning nécessaire, excellente interprétabilité

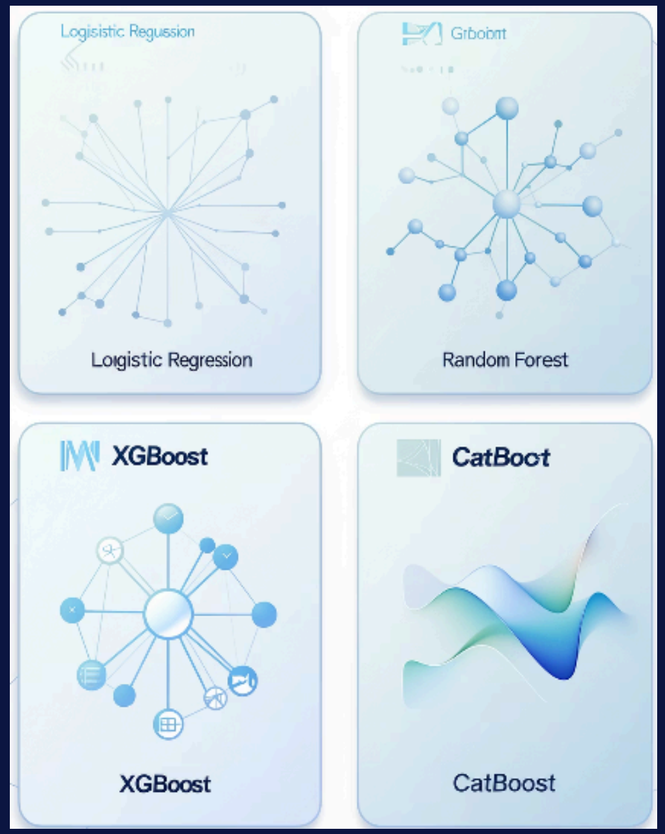

COMPARAISON

MODEL	RECALL	ROC-AUC
LOGISTIC REGRESSION	0.737	0.815
RANDOM FOREST	0.505	0.8
XGBOOST	0.838	0.85
CATBOOST	0.838	0.851
DECISION TREE	0.697	0.77

XGBOOST ET CATBOOST ONT CLAIREMENT DOMINÉ SUR TOUTES LES MÉTRIQUES.

CONCLUSION ET RECOMMANDATIONS

CE PROJET DE DÉTECTION DE FRAUDE EN ASSURANCE AUTOMOBILE A PERMIS DE DÉVELOPPER ET D'ÉVALUER QUATRE MODÈLES DE MACHINE LEARNING DISTINCTS SUR UN DATASET DE 400 SINISTRES AUTOMOBILES. L'OBJECTIF ÉTAIT D'IDENTIFIER AUTOMATIQUEMENT LES DÉCLARATIONS FRAUDULEUSES PARMI LES SINISTRES DÉCLARÉS, AFIN DE RÉDUIRE LES PERTES FINANCIÈRES ESTIMÉES À 200 MILLIONS DE DINARS EN TUNISIE.