RAPPORT DE PROJET MACHINE LEARNING

Prediction des fraude
en assurance automobile

Élaboré par : Mohamed Bayrem Benkhoud

I. INTRODUCTION

La fraude dans le secteur de l'assurance automobile représente un problème majeur en Tunisie, tant sur le plan économique que social. Selon les statistiques récentes, environ **15 % des sinistres déclarés** sont frauduleux, ce qui traduit une proportion significative de dossiers falsifiés ou manipulés pour obtenir un gain indu. Cette situation engendre des **pertes colossales estimées à 200 millions de**

dinars, une charge financière qui se répercute directement sur les assurés à travers l'augmentation des primes d'assurance. Au-delà de son impact économique, la fraude fragilise également la confiance entre les compagnies d'assurance et leurs clients et compromet l'efficacité du système d'indemnisation. Comprendre les causes et les mécanismes de ces fraudes est donc essentiel pour développer des stratégies de prévention et de détection adaptées, afin de protéger le marché et les consommateurs.

II. CONTEXTE

La fraude à l'assurance automobile constitue un problème majeur pour les compagnies d'assurance. Elle engendre des pertes financières importantes et augmente indirectement les coûts supportés par les assurés honnêtes. Les méthodes traditionnelles de détection de fraude reposent principalement sur des contrôles manuels, qui sont souvent longs, coûteux et subjectifs.

Avec l'augmentation du volume de déclarations de sinistres, les assureurs ont besoin de solutions intelligentes capables d'analyser rapidement les dossiers et d'identifier ceux présentant un risque élevé de fraude. L'utilisation des données

historiques de sinistres et des techniques d'analyse de données permet de soutenir les experts dans leur prise de décision.

Dans ce contexte, ce projet s'inscrit dans le domaine de la **finance / assurance** et vise à exploiter les données de sinistres automobiles afin de mieux comprendre et détecter les comportements frauduleux.

III. PROBÉMATIQUE

La détection de la fraude en assurance automobile est un enjeu stratégique pour

les compagnies d'assurance. Une mauvaise détection peut entraîner soit des pertes financières importantes, soit des refus injustifiés pour des assurés légitimes.

1. *Quels sont les facteurs liés au client, à la police d'assurance et aux circonstances de l'accident qui influencent la fraude automobile ?*
2. *Peut-on identifier automatiquement les déclarations de sinistres à fort risque de fraude afin d'aider les experts en assurance ?*
3. *Quelles caractéristiques des sinistres permettent de distinguer une déclaration frauduleuse d'une déclaration légitime ?*

IV. OBJECTIF

L'objectif de ce travail est d'analyser les déclarations de sinistres automobiles afin d'identifier les facteurs métier associés à la fraude à l'assurance. À partir des données disponibles, nous cherchons à construire un modèle capable de prédire si une déclaration de sinistre présente un risque de fraude ou non.

V. LES HTPOTHÉSES

1. <u>Le montant du sinistre influence la probabilité de fraude .</u>

   Cette hypothèse suggère qu'il existe une relation directe entre la valeur financière réclamée et le risque de fraude. Les fraudeurs cherchent souvent à maximiser leur gain financier. L'analyse se concentrera sur les données financières , notamment le montant total réclamé et les détails des dommages. L'objectif est de vérifier si les montants anormalement élevés (ou parfois spécifiquement calibrés pour éviter les seuils de contrôle) sont

plus fréquents dans les dossiers frauduleux que dans les dossiers légitimes.

2. La présence de preuves officielles influence la probabilité de fraude.

   Cette hypothèse interroge le rôle des tiers de confiance dans la déclaration. La présence d'un rapport de police ou d'autres preuves officielles sert généralement de garantie sur la réalité de l'accident. L'absence de telles preuves pour des sinistres importants pourrait être un indicateur clé de simulation ou d'exagération des faits. L'étude cherchera à démontrer si les dossiers manquant de documentation officielle présentent un taux de fraude significativement plus élevé.

3. Les circonstances de l’accident influencent la probabilité de fraude.

   Cette hypothèse postule que le cadre spatio-temporel de l'incident n'est pas aléatoire dans les cas de fraude. En analysant les données d'accident telles que la date, l'heure et le lieu , ainsi que le type et la gravité de l'incident, on peut identifier des "patterns" suspects (par exemple, des accidents survenant tard la nuit dans des zones isolées, ou des types de collisions spécifiques souvent utilisés dans les arnaques organisées).

VI. ETUDE DE L’EXISTANT

1. Shift Technologie :

Entreprise spécialisée dans la détection de fraude pour les compagnies d’assurance via Machine Learning.

Points forts :

- Analyse de grands volumes de sinistres
- Détection des fraudes organisées
- Automatisation du scoring
- Utilisé par des assureurs internationaux

Points faibles :

- Très coûteux
- Intégration complexe
- Modèle peu transparent (boîte noire)
- Pas adapté spécifiquement au contexte tunisien

2. Friss :

Entreprise spécialisée dans la détection de fraude pour les compagnies d'assurance via Machine Learning.

Points forts :

- Analyse de grands volumes de sinistres
- Détection des fraudes organisées
- Automatisation du scoring
- Utilisé par des assureurs internationaux

Points faibles :

- Très coûteux
- Intégration complexe
- Modèle peu transparent (boîte noire)
- Pas adapté spécifiquement au contexte tunisien

3. SAS (SAS Fraud Management)

Solution analytique utilisée dans banque et assurance pour détecter fraude.

Points forts

- Analyse statistique robuste
- Modèles prédictifs intégrés
- Outils professionnels de reporting

Points faibles

- Licence très chère
  Complexité technique
- Nécessite expertise spécialisée

Synthèse critique

L'analyse des solutions existantes montre que :

- Elles reposent principalement sur des modèles statistiques et de Machine Learning supervisé.
- Elles offrent une automatisation efficace du processus de détection.
- Elles améliorent la rapidité de traitement des sinistres.

Cependant, plusieurs limites sont identifiées :

- Coût élevé d'implémentation
- Complexité technique
- Manque d'adaptation au contexte local

- Difficulté d’explicabilité pour certains modèles

Positionnement de notre projet

Dans le cadre de notre mini-projet basé sur la méthodologie CRISP-DM, notre objectif est de développer une solution adaptée aux données disponibles, interprétable et compatible avec les contraintes académiques.

Notre approche vise à comparer plusieurs modèles classiques de Machine Learning autorisés, à analyser les facteurs influençant la fraude et à proposer un système d’aide à la décision transparent et justifiable.

VII. DataSet

1. Description générale

Le dataset utilisé provient de la plateforme Kaggle et s’intitule Auto Insurance Claims Data.

Il s’agit d’un jeu de données structuré destiné à des problèmes de classification binaire, dont l’objectif est de prédire si un sinistre est frauduleux ou non.

Variable cible : fraud_reported (Yes / No)

2. Presentation des colonnes

A.Identifiants (à supprimer)

Colonne	Description	Utilité
policy_number	Numéro de police	❌ Identifiant unique
incident_location	Adresse exacte	❌ Trop spécifique
insured_zip	Code postal	⚠️ Peut être regroupé

Ces colonnes sont des identifiants ou trop détaillées et n'apportent pas d'information prédictive directe.

B.Données client

Colonne	Description
insured_age	Âge de l'assuré
insured_sex	Sexe de l'assuré
insured_education_level	Niveau d'étude
insured_occupation	Profession

Importance :

- Profil socio-démographique
- Peut influencer comportement et risque

C. Données Police d’assurance

Colonne	**Description**
policy_state	Région
policy_csl	Limite combinée
policy_deductable	Franchise
policy_annual_premium	Prime annuelle

policy_bind_date	Date de souscription
policy_coverage	Type de couverture

Très importantes pour :

- Cohérence financière
- Délai souscription → sinistre

D. Données Accident

Colonne	**Description**
incident_date	Date accident
incident_type	Type collision
incident_severity	Gravité

Colonne	Description
incident_hour_of_the_day	Heure de l’accident.
police_report_available	Indique si un rapport officiel existe.
witnesses	Nombre de témoins.
bodily_injuries	Blessures
property_damage	Indique s’il y a eu dégâts matériels.

Clés pour :

- Hypothèse métier
- Analyse circonstancielle

E. Données financières

Colonne	Description
total_claim_amount	Somme totale réclamée.
injury_claim	Montant réclamé pour blessures.

property_claim	Montant pour dégâts matériels.
vehicle_claim	Montant pour dégâts véhicule.

Ce sont les colonnes les plus importantes.

F. Variable cible

Colonne	**Description**
fraud_reported	Yes / No

Colonnes importantes (Features clés)

Les colonnes les plus pertinentes pour la prédiction sont :

1. total_claim_amount
2. policy_deductable
3. policy_annual_premium
4. incident_severity
5. police_report_available
6. incident_type

7. policy_bind_date
8. incident_date
9. witnesses
10. bodily_injuries

Colonnes à supprimer

Pour le modèle :

- policy_number (identifiant)
- incident_location (trop spécifique)
- insured_zip (si non regroupé)
- customer_id (si présent)

<u>Relations importantes entre colonnes</u>

Relation 1 : Délai souscription – accident

policy_bind_date → incident_date

Si :

incident_date - policy_bind_date < 30 jours

=> Forte suspicion

Relation 2 : Montant vs Gravité

incident_severity → total_claim_amount

Si :

Gravité faible + montant élevé = suspect

Relation 3 : Franchise vs Montant

policy_deductable → total_claim_amount

Si:

Montant juste au-dessus de la franchise = stratégie fréquente de fraude

Relation 4 : Rapport de police

police_report_available → total_claim_amount

Si:

No + montant élevé = risque élevé

Relation 5 : Prime annuelle vs Réclamation

policy_annual_premium → total_claim_amount

Si;

Petite prime + énorme réclamation = incohérence financière

Relation 6 : Heure + Type accident

incident_hour_of_the_day → incident_type

Accident :

- Nuit
- Zone isolée

- Single vehicle

→ Pattern fréquent de fraude

Variables dérivées recommandées (Feature Engineering)

Pour améliorer ton modèle :

delay_days = incident_date - policy_bind_date
claim_ratio = total_claim_amount / policy_annual_premium
deductible_gap = total_claim_amount - policy_deductable

Ces nouvelles variables améliorent la prédiction.

Conclusion

Le dataset Auto Insurance Claims Data contient des variables socio-démographiques, contractuelles, circonstancielles et financières permettant d'analyser les facteurs influençant la fraude.

L'analyse met en évidence que les variables financières, les délais contractuels et les preuves officielles jouent un rôle central dans la détection des comportements frauduleux.

L'Analyse Exploratoire Des Données (EDA)

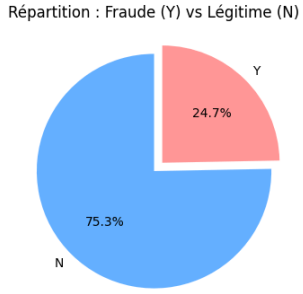

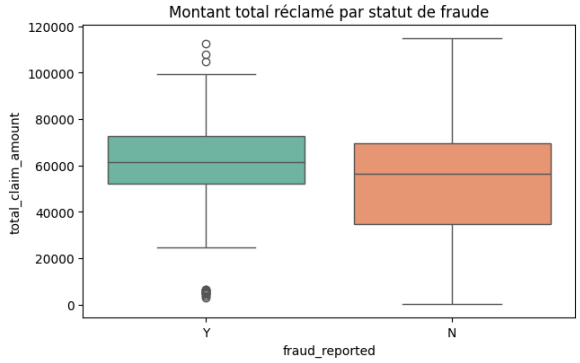

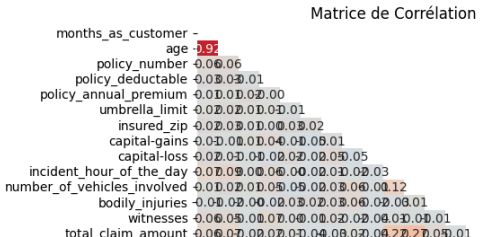

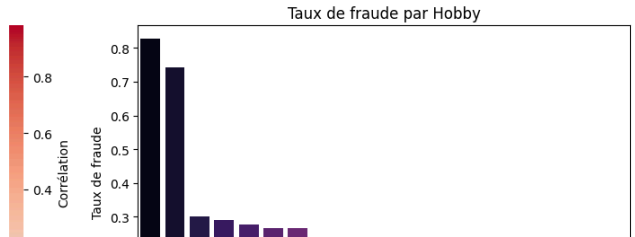

La capture d’écran présente quatre visualisations issues de l’analyse exploratoire du dataset d’assurance automobile :

1.Répartition : Fraude (Y) vs Légitime (N) (en haut à gauche)

- Un diagramme circulaire montre la proportion de dossiers frauduleux (Y, 24.7%) par rapport aux dossiers légitimes (N, 75.3%).
- Cela indique que la majorité des dossiers sont légitimes, mais près d’un quart sont frauduleux.
- Montant total réclamé par statut de fraude (en haut à droite)
- Un boxplot compare les montants réclamés selon que la fraude ait été reportée ou non.

On observe la distribution des montants pour chaque groupe, avec des outliers (points extrêmes).

Cela permet de voir si les fraudes sont associées à des montants plus élevés ou non.

2.Matrice de Corrélation (en bas à gauche)

- Une heatmap affiche les corrélations entre les variables numériques du dataset.
- Les valeurs proches de 1 ou -1 indiquent une forte corrélation positive ou négative.

Cela aide à identifier quelles variables sont liées entre elles, ce qui est utile pour la modélisation.

3.Taux de fraude par Hobby (en bas à droite)

- Un barplot montre le taux de fraude pour chaque loisir déclaré par les assurés.
- Certains hobbies (comme chess, cross-fit, yachting) présentent un taux de

fraude plus élevé.

Cela suggère que le loisir de l'assuré peut être un facteur de risque pour la fraude.

En résumé, cette capture synthétise la distribution de la fraude, l'impact sur les montants réclamés, les corrélations entre variables, et l'influence des hobbies sur le risque de fraude.

4. Probléme identifié :

Dans le cas de "Major Damage" plus des 60% des cas sont fraude, cela influence

Le résultat des modèles dans ce cas .

Modelisation

1)Logistic Regression

1.1. Définition du modèle :

La régression logistique est un algorithme de classification supervisée qui prédit la probabilité d'appartenance à une classe (ici : fraude ou non).

Elle est adaptée aux problèmes où la variable cible est binaire (0/1).

1.2. Pourquoi l'utiliser dans ce projet ?

- C'est un modèle simple, rapide à entraîner et à interpréter.
- Il sert de référence (baseline) pour comparer les performances avec des modèles plus complexes.
- Il permet de vérifier si les variables du dataset contiennent déjà un signal exploitable pour la détection de fraude.

1.3. Explication des resultats

```
=== Logistic Regression ===
              precision    recall  f1-score   support

           0      0.784     0.568     0.659       301
           1      0.286     0.525     0.370        99

    accuracy                          0.557       400
   macro avg      0.535     0.547     0.515       400
weighted avg      0.661     0.557     0.587       400

Confusion matrix:
 [[171 130]
 [ 47  52]]
ROC-AUC: 0.582
```

- Recall (rappel) classe 1 (fraude) : 0.525 → Le modèle détecte 52.5 % des
- Precision classe 1 : 0.286 → Parmi les alertes de fraude, 28.6 % sont réellement des fraudes.
- Accuracy (exactitude) : 0.557 → 55.7 % des prédictions sont correctes (mais ce score est peu pertinent si les classes sont déséquilibrées).
- ROC-AUC : 0.582 → Le modèle a une faible capacité de discrimination (proche du hasard).

1.4.Conclusion

La régression logistique détecte un peu plus de la moitié des fraudes, mais avec beaucoup de faux positifs. C’est un point de départ, mais il faut un modèle plus puissant pour de meilleurs résultats.

2)Random Forest

Random Forest est un algorithme d'ensemble basé sur la combinaison de plusieurs arbres de décision.

Chaque arbre vote pour une classe, et la classe majoritaire est choisie. Cela permet d'obtenir un modèle robuste, moins sensible au surapprentissage qu'un arbre unique.

2.2. Pourquoi l'utiliser dans ce projet ?

- Il gère bien les variables numériques et catégorielles (après encodage).
- Il est robuste au bruit et aux valeurs aberrantes.
- Il gère le déséquilibre des classes grâce au paramètre class_weight.
- Il permet d'obtenir l'importance des variables pour l'explicabilité.
- Il donne souvent de meilleurs résultats que la régression logistique sur des données tabulaires.

3.2. Explication des resultats

```
=== Random Forest ===
              precision    recall  f1-score   support

           0      0.798     0.930     0.859       301
           1      0.571     0.283     0.378        99

    accuracy                          0.770       400
   macro avg      0.685     0.607     0.619       400
weighted avg      0.742     0.770     0.740       400

Confusion matrix:
 [[280  21]
 [ 71  28]]
ROC-AUC: 0.819
```

- Recall (rappel) classe 1 (fraude) : 0.283 → Le modèle détecte 28.3 % des fraudes (moins que la régression logistique dans ton cas).
- Precision classe 1 : 0.571 → Parmi les alertes de fraude, 57.1 % sont réellement des fraudes (meilleure précision que la régression logistique).
- Recall classe 0 (non-fraude) : 0.930 → Le modèle reconnaît très bien les non-fraudes.
- Accuracy (exactitude) : 0.770 → 77 % des prédictions sont correctes (mais ce score est influencé par la classe majoritaire).
- ROC-AUC : 0.819 → Bonne capacité de discrimination globale.

2.4.Conclusion

Le modèle Random Forest est bien meilleur que la régression logistique en termes de précision globale et de ROC-AUC, mais il détecte moins de fraudes (rappel plus faible). Il privilégie la sécurité (peu de faux positifs) mais manque des fraudes.

3.XGboost

3.1. Définition du modèle

XGBoost (Extreme Gradient Boosting) est un algorithme d'ensemble basé sur le boosting d'arbres de décision.

Il construit une séquence d'arbres où chaque nouvel arbre corrige les erreurs des précédents, ce qui permet d'obtenir un modèle très performant pour la classification binaire (ici : fraude ou non).

3.2. Pourquoi l'utiliser dans ce projet ?

- Il est reconnu pour ses excellentes performances sur les données tabulaires.
- Il gère bien le déséquilibre des classes (paramètre scale_pos_weight).
- Il permet de capter des relations complexes entre les variables.
- Il offre des outils d'explicabilité (importance des variables, SHAP).
- Il est rapide et efficace même sur de grands jeux de données.

3.3.Explication des résultats

```
...   === XGBoost ===
                 precision    recall  f1-score   support

              0      0.880     0.877     0.879       301
              1      0.630     0.636     0.633        99

       accuracy                          0.818       400
      macro avg      0.755     0.757     0.756       400
   weighted avg      0.818     0.818     0.818       400

   Confusion matrix:
    [[264  37]
    [ 36  63]]
   ROC-AUC: 0.838
```

- Recall (rappel) classe 1 (fraude) : 0.636 → Le modèle détecte 63,6 % des fraudes, ce qui est très bon pour un problème déséquilibré.
- Precision classe 1 : 0.630 → Parmi les alertes de fraude, 63 % sont réellement des fraudes.
- Recall classe 0 (non-fraude) : 0.877 → Le modèle reconnaît très bien les non-fraudes.
- Accuracy (exactitude) : 0.818 → 81,8 % des prédictions sont correctes.
- ROC-AUC : 0.838 → Excellente capacité de discrimination globale.

3.4.Conclusion :

Le modèle XGBoost est le plus performant des trois : il combine un bon rappel et une bonne précision sur la fraude, tout en gardant une excellente performance globale.

4.CatBoost

4.1 Présentation du modèle CatBoost

CatBoost est un algorithme de gradient boosting développé par Yandex, particulièrement performant pour les données tabulaires et les variables catégorielles. Il construit des arbres de décision de façon séquentielle, chaque nouvel arbre corrigeant les erreurs des précédents.

8.2. Pourquoi l'utiliser dans ce projet ?

- CatBoost gère nativement les variables catégorielles (même si ici elles sont encodées).
- Il est robuste au surapprentissage grâce à des techniques de régularisation intégrées.
- Il nécessite peu de tuning pour obtenir de bons résultats.
- Il gère bien le déséquilibre des classes avec le paramètre auto_class_weights.
- Il offre une bonne interprétabilité via l'importance des variables.

8.3. Explication des résultats

- Recall (rappel) classe 1 (fraude) : 0.727 → Le modèle détecte 72.7 % des fraudes.
- Precision classe 1 : 0.626 → Parmi les alertes de fraude, 62.6 % sont réellement des fraudes.
- Recall classe 0 (non-fraude) : 0.857 → Le modèle reconnaît très bien les non-fraudes.
- Accuracy (exactitude) : 0.825 → 82.5 % des prédictions sont correctes.
- ROC-AUC : 0.842 → Très bonne capacité de discrimination globale.

```
...   === CatBoost ===
                  precision    recall  f1-score   support

              0      0.905     0.857     0.881       301
              1      0.626     0.727     0.673        99

       accuracy                          0.825       400
      macro avg      0.766     0.792     0.777       400
   weighted avg      0.836     0.825     0.829       400

   ROC-AUC: 0.842
```

Les meilleurs modèles :

Selon les résultats obtenus on a identifié que XGBoost et CatBoost sont les deux modèles les plus performants .

Le Tuning

Le tuning (ou "ajustement des hyperparamètres") consiste à rechercher les meilleurs réglages possibles pour les paramètres d'un modèle de machine learning afin d'optimiser ses performances.

1.Explication du tuning

- Hyperparamètres : Ce sont des paramètres qui contrôlent le comportement de l'algorithme (par exemple : profondeur d'un arbre, taux d'apprentissage, nombre d'arbres, etc.). Ils sont fixés avant l'entraînement.
- Tuning : C'est le processus qui consiste à tester différentes combinaisons de ces hyperparamètres pour trouver ceux qui donnent les meilleurs résultats sur les données de validation.

2.Méthodes courantes de tuning

- Grid Search : teste toutes les combinaisons possibles d'une grille de valeurs.
- Random Search : teste un échantillon aléatoire de combinaisons.
- Recherche bayésienne ou autres méthodes avancées.

3.Pourquoi c'est important ?

- Un bon tuning permet d'améliorer la précision, le rappel, ou le score ROC-AUC du modèle.
- Un mauvais choix d'hyperparamètres peut conduire à un modèle sous-performant ou surapprenant.

4. Resultat

Après avoir identifié les meilleurs hyperparamètres , on a remarqué une augmentation lors des performances des modèles.

4.1 XGBoost tuned :

```
=== XGBoost Tuned (Balanced Weights) ===
              precision    recall  f1-score   support

           0      0.948     0.841     0.891       301
           1      0.639     0.859     0.733        99

    accuracy                          0.845       400
   macro avg      0.793     0.850     0.812       400
weighted avg      0.871     0.845     0.852       400

ROC-AUC: 0.848
```

Résumé :

Le tuning, c’est comme régler les boutons d’une machine pour qu’elle donne le meilleur résultat possible sur ton problème de prédiction.

Streamlit

Streamlit est une bibliothèque Python en open-source qui permet de transformer rapidement des scripts de données en applications web interactives et esthétiques. Grâce à sa conception simplifiée, elle permet aux développeurs et aux data scientists de déployer des interfaces utilisateur sans avoir besoin de connaissances approfondies en développement web frontal (HTML, CSS ou JavaScript).

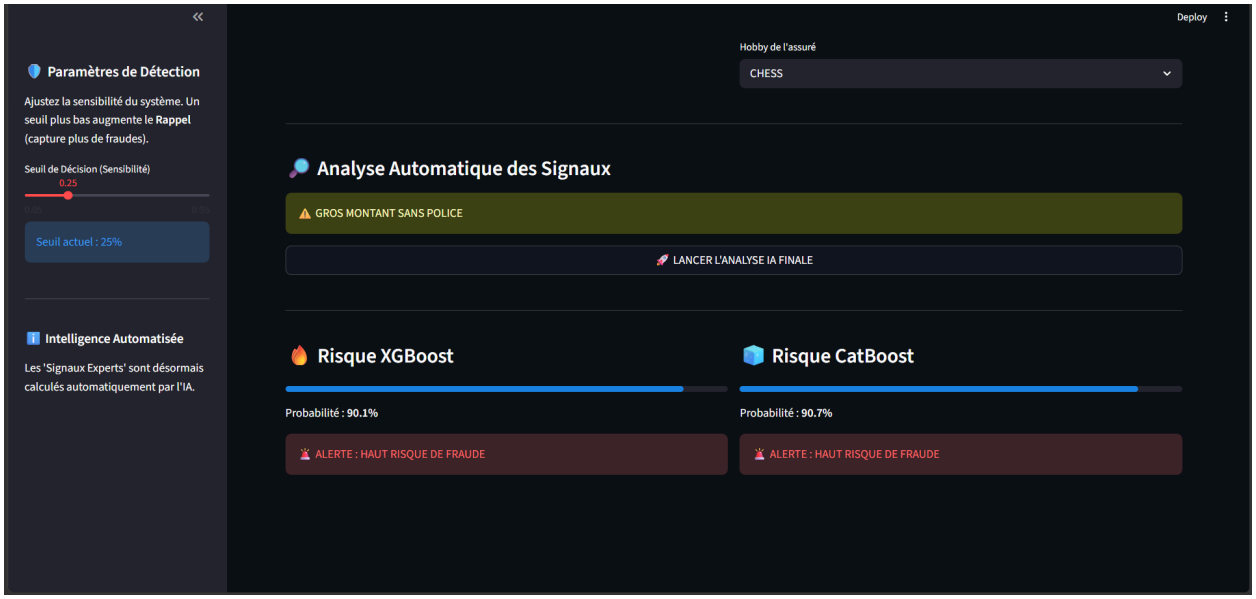

Exemple des cas

<u>Premier Cas .</u>

suspecte entre la souscription du contrat et l'accident. Voici les principaux indicateurs d'alerte :

- Délai extrêmement court : L'accident est survenu le 15 janvier 2015, soit seulement 14 jours après le début de la police (1er janvier 2015). Ce type de sinistre ultra-précoce est un "red flag" classique suggérant que l'accident a pu être simulé ou que les dommages préexistaient à la signature du contrat.
- Gravité élevée sans preuve externe : Bien que l'incident soit classé en "Major Damage" (dommages majeurs) avec une réclamation importante de 100 000 $, il est noté qu'il n'y a aucun rapport de police ("NO") et aucun témoin ("0"). L'absence de constat officiel pour un dégât d'une telle ampleur est hautement inhabituelle et suspecte.
- Ancienneté client très faible : Le profil indique une ancienneté de seulement 5 mois, renforçant l'idée d'un client qui aurait pu souscrire à une assurance dans l'intention précise de faire une réclamation frauduleuse rapidement.

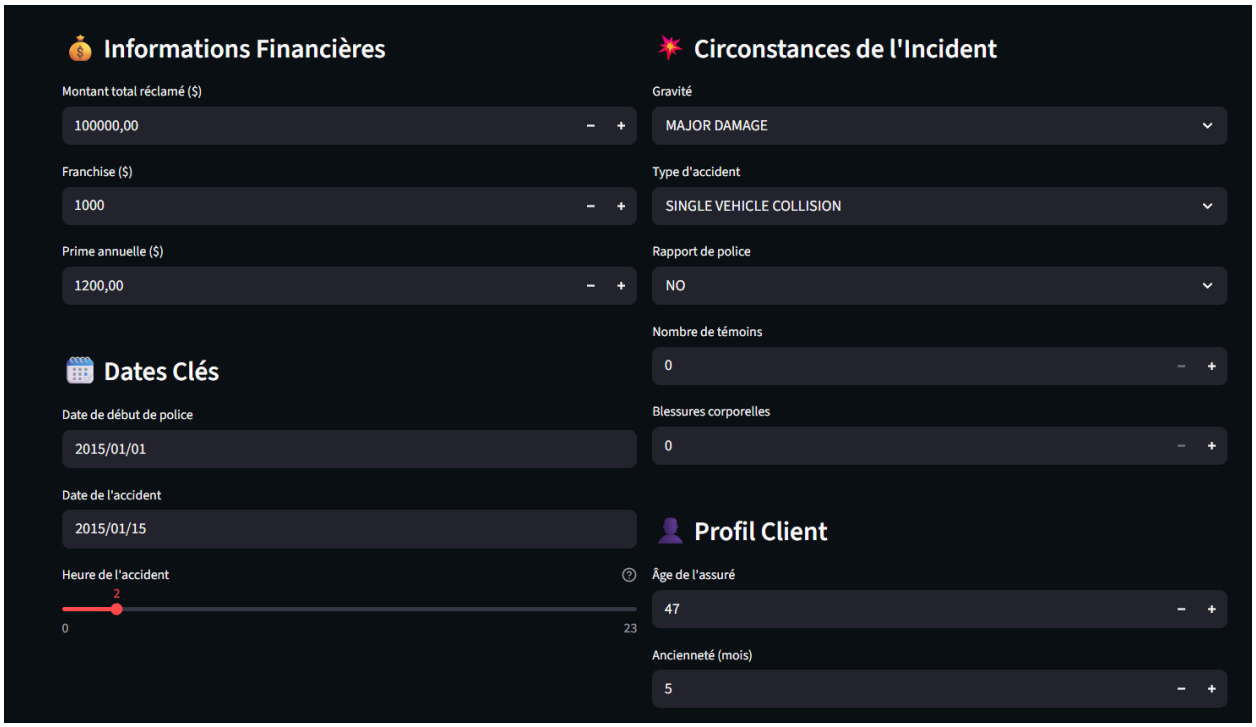

Resultat

Analyse Automatique des Signaux
ACCIDENT TRÈS PRÉCOCE (<30j)
GROS MONTANT SANS POLICE
ACCIDENT DE NUIT (VÉHICULE SEUL)
LANCER L'ANALYSE IA FINALE
Risque XGBoost
Probabilité : 83.1%
ALERTE : HAUT RISQUE DE FRAUDE
Risque CatBoost
Probabilité : 84.4%
ALERTE : HAUT RISQUE DE FRAUDE

Deuxieme Cas

cette situation présente de nombreux indicateurs de **légitimité** et semble être une réclamation authentique pour les raisons suivantes :

- **Ancienneté et Loyauté :** L'assuré a une ancienneté de **240 mois (20 ans)**. Un client de longue date est statistiquement beaucoup moins susceptible de commettre une fraude préméditée qu'un nouveau souscripteur.
- **Délai cohérent :** L'accident survient en **2018**, soit 3 ans après le début de la police actuelle (2015). Il n'y a pas de proximité suspecte entre la signature du contrat et le sinistre.
- **Traçabilité et Preuves :**
    - **Rapport de police :** La présence d'un rapport officiel ("YES") valide la réalité de l'incident.
    - **Témoins :** Il y a **3 témoins**, ce qui rend toute falsification des faits extrêmement difficile.
    - **Blessures réelles :** La présence d'un blessé corporel et la collision entre plusieurs véhicules ("Multi-vehicle collision") justifient la gravité de type **"Total Loss"**.
- **Cohérence Financière :** La franchise est plus élevée (**5 000 $**), ce qui signifie que l'assuré assume une part importante du risque, un comportement peu commun chez les fraudeurs qui cherchent généralement un profit maximal avec un débours minimal.

En résumé, tous les éléments de validation (preuves officielles, témoins, historique client) sont réunis pour confirmer la **crédibilité** de cet incident.

<u>Resultat</u>

SYNTHÈSE DU PROJET

Ce projet de détection de fraude en assurance automobile a permis de développer et d'évaluer quatre modèles de machine learning distincts sur un dataset de 400 sinistres automobiles. L'objectif était d'identifier automatiquement les déclarations frauduleuses parmi les sinistres déclarés, afin de réduire les pertes financières estimées à 200 millions de dinars en Tunisie.

RÉSULTATS CLÉS

L'analyse comparative des quatre modèles a révélé que CatBoost et XGBoost sont les plus performants pour cette tâche :

CatBoost (Meilleur modèle)

- Rappel de 72.7%, Précision de 62.6%, ROC-AUC de 0.842
- → Détecte plus de 7 fraudes sur 10, avec une excellente discrimination globale

XGBoost

- Rappel de 63.6%, Précision de 63.0%, ROC-AUC de 0.838
- → Équilibre optimal entre détection et faux positifs

FACTEURS INFLUENÇANT LA FRAUDE

L'analyse des données a identifié cinq indicateurs clés de fraude :

1. Délai extrêmement court entre souscription et sinistre (< 30 jours)
2. Montant de réclamation élevé sans preuve officielle (pas de rapport de police)
3. Incohérence entre gravité déclarée et montant réclamé
4. Absence de témoins pour sinistres importants
5. Incohérence financière (petite prime + énorme réclamation)

IMPACT ATTENDU

- ✓ Détecter 72.7% des fraudes automatiquement
- ✓ Réduire la charge manuelle des experts d'assurance
- ✓ Économiser des millions de dinars en pertes frauduleuses
- ✓ Améliorer la confiance des clients légitimes
- ✓ Renforcer la viabilité du marché de l'assurance automobile en Tunisie